TRABAJO PRÁCTICO INTEGRADOR · ENTREGA 4

Unidad N° 4: Análisis Exploratorio de Datos (Semana 9 + Semana 10)

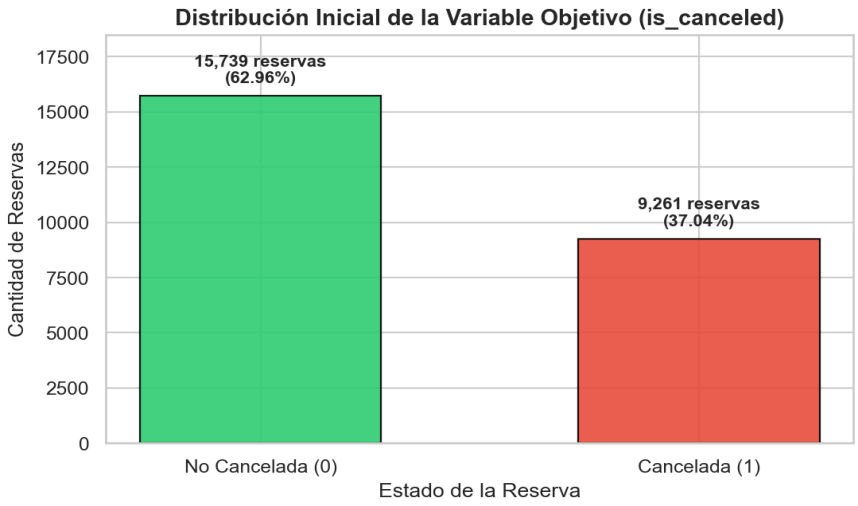
Campo Académico	Detalle
Institución / Carrera	UTN — Tecnicatura Universitaria en Programación a Distancia (TUPaD)
Materia	Introducción al Análisis de Datos (IAD)
Comisión	Comisión 8
Integrantes	López, Emanuel Gustavo (Legajo: 101135) · Del Corro, Santino
Dataset Asignado	hotel booking TPI grupo H.csv (Grupo H — 25.000 registros)
Variable Objetivo	is_canceled (0 = Reserva No Cancelada / Efectivizada, 1 = Cancelada)
Recorrido Elegido	SQL (DuckDB) + Python (pandas, matplotlib, seaborn)

PRIMERA PARTE · Avance de la Semana 9 (Exploración Univariada y Estructura)

1. Unidad de Análisis y Variable Objetivo: Cada fila de la tabla *reservas* representa una **reserva hotelera individual** identificada unívocamente por *booking_id* (25.000 filas = 25.000 reservas únicas, sin duplicados). La variable objetivo **is_canceled** es binaria: **0** indica reserva efectivizada (15.739 casos; 62,96%) y **1** indica reserva cancelada (9.261 casos; 37,04%).

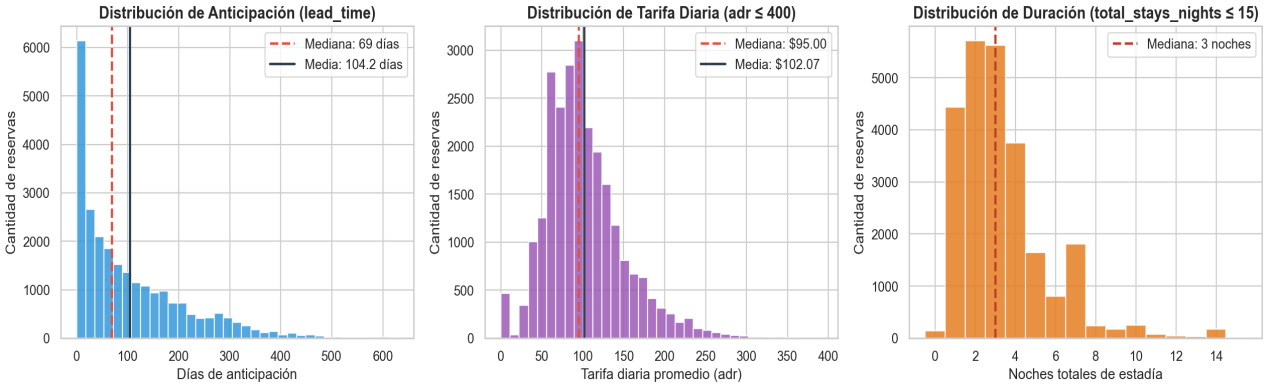
2. Preparación Mínima Reconstruida (Continuidad Entregas 2 y 3): Imputación de nulos en *children* (0), *country* ('Unknown'), *agent* (0) y *company* (0); creación de **total_stays_nights** (*stays_in_weekend_nights* + *stays_in_week_nights*) y **total_guests** (*adults* + *children* + *babies*).

Estado de Reserva (is_canceled)	Cantidad (SQL COUNT)	Porcentaje (%)
No Cancelada (0)	15.739	62,96 %
Cancelada (1)	9.261	37,04 %
Total General	25.000	100,00 %



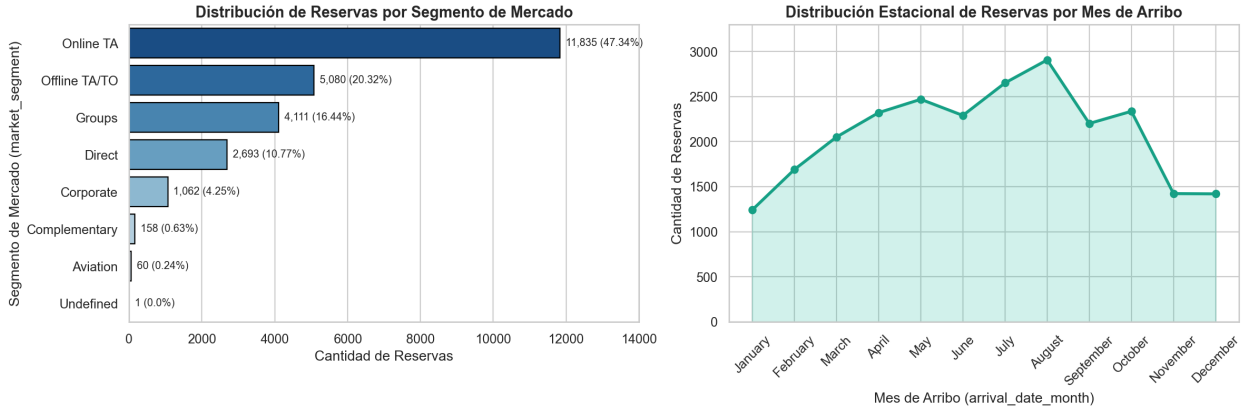
3. Resumen Descriptivo SQL de Variables Cuantitativas Seleccionadas

Variable Cuantitativa	n	Media	Desv. Est.	Mín	Q1 (25%)	Mediana	Q3 (75%)	Máx
lead_time (días anticipación)	25.000	104,22	107,32	0	18,0	69,0	160,0	629
adr (tarifa diaria promedio)	25.000	$102,07	$58,73	$0,00	$69,92	$95,00	$126,00	$5.400,00
total_stays_nights (noches)	25.000	3,43	2,58	0	2,0	3,0	4,0	69



4. Distribuciones de Variables Categóricas y Temporales (hotel, market_segment, arrival_date_month)

• **hotel:** City Hotel concentra 16.610 reservas (66,44%) y Resort Hotel 8.390 reservas (33,56%).
• **market_segment:** Predominan Online TA (11.835; 47,34%), Offline TA/TO (5.080; 20,32%), Groups (4.111; 16,44%), Direct (2.693; 10,77%) y Corporate (1.062; 4,25%).
• **arrival_date_month:** Máxima actividad en agosto (2.906; 11,62%) y julio (2.651; 10,60%); mínima en enero (1.242; 4,97%).

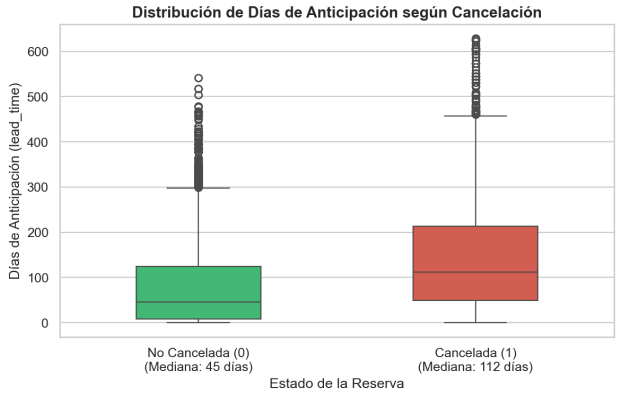


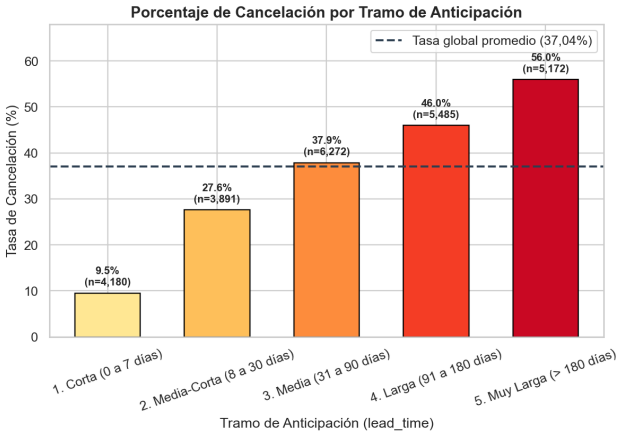
SEGUNDA PARTE · Entrega 4 (Semana 10): Comparación de Grupos y Hallazgos

Pregunta / Hipótesis 1: Anticipación de la Reserva (lead_time) vs. Cancelación

¿En qué medida difiere la distribución de los días de anticipación (lead_time) entre las reservas canceladas y las no canceladas, y cómo evoluciona la tasa de cancelación a través de los distintos tramos de anticipación?

Estado / Tramo de Anticipación	Cantidad (n)	Canceladas	Tasa Cancelación	Media / Mediana (RIC)
Estado: No Cancelada (0)	15.739	0	0,00 %	Media: 80,28 d | Mediana: 45,0 d (RIC: 116)
Estado: Cancelada (1)	9.261	9.261	100,00 %	Media: 144,89 d | Mediana: 112,0 d (RIC: 164)
Tramo 1: Corta (0 a 7 días)	4.180	397	9,50 %	ADR medio: $89,39
Tramo 2: Media-Corta (8 a 30 días)	3.891	1.073	27,58 %	ADR medio: $107,78
Tramo 3: Media (31 a 90 días)	6.272	2.374	37,85 %	ADR medio: $108,05
Tramo 4: Larga (91 a 180 días)	5.485	2.522	45,98 %	ADR medio: $109,77
Tramo 5: Muy Larga (> 180 días)	5.172	2.895	55,97 %	ADR medio: $92,59





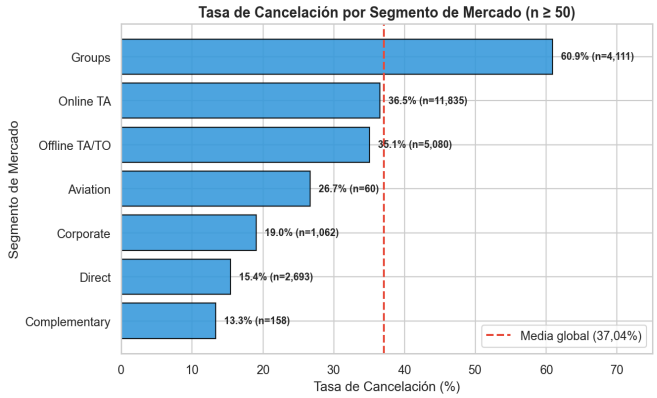
Resultado vs. Interpretación: Los datos muestran que la mediana de anticipación en reservas canceladas (112 días) más que duplica la de las no canceladas (45 días), y la tasa sube monótonamente del 9,50% al 55,97%. Analíticamente, un horizonte lejano incrementa la incertidumbre del huésped, aunque parte de este efecto se superpone con bloqueos grupales de largo plazo.

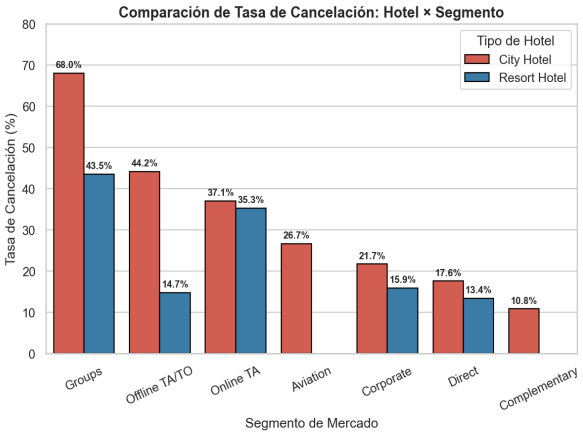
Pregunta / Hipótesis 2: Tipo de Hotel (hotel) y Segmento de Mercado (market_segment)

¿Qué diferencias existen en la proporción de cancelaciones según el tipo de hotel y el segmento de mercado, tanto individualmente como al cruzar ambas dimensiones?

Hotel / Segmento (n >= 50)	Total Reservas (n)	Canceladas	Tasa Cancelación (%)	Lead Time Medio
City Hotel (Total)	16.610	6.930	41,72 %	110,2 días
Resort Hotel (Total)	8.390	2.331	27,78 %	92,4 días
City Hotel × Groups	2.916	1.984	68,04 %	194,5 días
City Hotel × Offline TA/TO	3.505	1.549	44,19 %	143,6 días
City Hotel × Online TA	8.128	3.013	37,07 %	83,2 días
City Hotel × Direct	1.309	230	17,57 %	51,3 días
Resort Hotel × Groups	1.195	520	43,51 %	168,6 días
Resort Hotel × Online TA	3.707	1.308	35,28 %	83,5 días

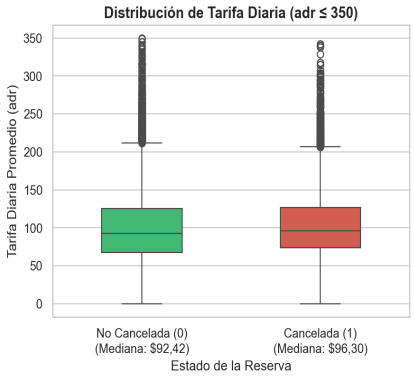
Hotel / Segmento (n >= 50)	Total Reservas (n)	Canceladas	Tasa Cancelación (%)	Lead Time Medio
Resort Hotel × Offline TA/TO	1.575	232	14,73 %	118,6 días
Resort Hotel × Direct	1.384	185	13,37 %	49,9 días

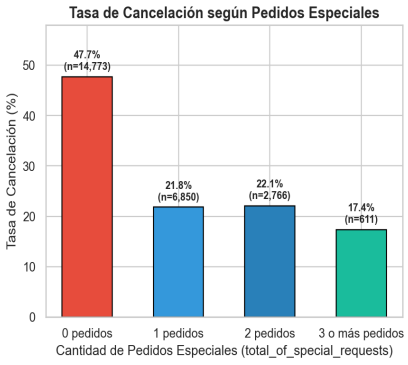


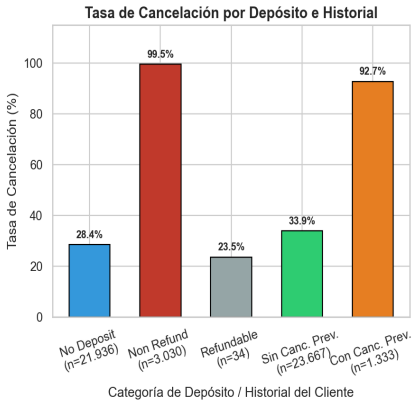


Pregunta / Hipótesis 3: Estadía, Tarifa (adr) y Compromiso (deposit_type, previous_cancellations, requests)

Dimensión Comparada	Grupo / Categoría	Casos (n)	Métrica / Tasa de Cancelación
Duración (total_stays_nights)	No Cancelada (0) vs. Cancelada (1)	15.739 / 9.261	Mediana idéntica: 3,0 vs. 3,0 noches (Media: 3,40 vs. 3,48
Tarifa Diaria (adr)	No Cancelada (0) vs. Cancelada (1)	15.739 / 9.261	Mediana: $92,42 vs. $96,30 (Media: $99,97 vs. $105,63)
Pedidos Especiales	0 pedidos vs. 1 pedido vs. >=3	14.773 / 6.850 / 611	Tasa baja de 47,74% (0 ped.) a 21,80% (1 ped.) y 17,35%
Cancelaciones Previas	Sin previas (0) vs. Con previas (>0)	23.667 / 1.333	Tasa salta de 33,91% (sin previas) a 92,72% (con previas)
Tipo de Depósito	No Deposit vs. Non Refund	21.936 / 3.030	No Deposit: 28,43% cancelado | Non Refund: 99,54% can







Patrones y Casos Llamativos (Sin eliminación automática)

1. **Outlier extremo de tarifa:** 1 reserva (*HB-048516*, City Hotel, cancelada) registra **adr = $5.400,00**.
2. **Registros con valores cero: 423 casos** con *adr <= 0* (cortesías/canjes), **141 casos** con *total_stays_nights = 0* (uso diurno) y **32 casos** con *total_guests = 0* (inconsistencia operativa).
3. **Comportamiento anómalo de Non Refund:** 3.030 reservas con **99,54% de cancelación** y *lead_time* medio de 210,9 días, atribuible a bloqueos grupales/operadores o posible *data leakage* administrativo.

Variables Candidatas Justificadas, Conclusiones y Limitaciones

• **Variables Candidatas Seleccionadas: lead_time** (muy alta relevancia), **market_segment** (muy alta), **total_of_special_requests** (alta señal de compromiso), **previous_cancellations** (alta persistencia conductual), **hotel** (alta), **deposit_type** (alta, evaluando posible leakage) y **adr / arrival_date_month** (complementarias).
• **Tres Hallazgos Centrales:** (1) La anticipación duplica su mediana en las reservas canceladas (112 vs. 45 días); (2) El City Hotel (41,72%) y el segmento Groups (60,91%) concentran la mayor vulnerabilidad comercial; (3) El compromiso del cliente (pedidos especiales) y sus antecedentes discriminan mucho mejor que la duración de la estadía aislada.
• **Alcances y Limitaciones:** (1) Las asociaciones bivariadas no demuestran causalidad directa debido a variables confusoras (ej. Groups tiene alto lead_time); (2) El posible *data leakage* en *Non Refund* y los valores extremos requieren validación antes del modelado predictivo.